

Sistema de Percepción Autónoma para Detección de Barcos de Carga en Entornos Portuarios mediante Visión Artificial y Redes Neuronales Convolucionales

David Alejandro Poveda Jimenez

Código Estudiantil: 7004156

Ingeniería Mecatrónica UMNG – Inteligencia Artificial

Resumen—Este documento presenta el diseño, desarrollo y validación integral de un sistema de clasificación binaria (barco / no barco) basado en Redes Neuronales Convolucionales (CNN), concebido para integrarse en la carga útil de percepción y visión artificial de un Vehículo Aéreo No Tripulado (UAV). Utilizando un conjunto de datos de imágenes aéreas satelitales (80×80 píxeles, RGB), se implementó un pipeline riguroso que abarca la normalización espacial, la extracción automática de descriptores visuales jerárquicos y una validación cruzada estratificada de 5 pliegues (5-folds). El modelo optimizado alcanzó un Accuracy global promedio del 98,71 % y un F1-Score de 0,9740, superando el umbral de exigencia institucional. Asimismo, se desarrolló una Interfaz de Usuario (UI) interactiva para la validación en tiempo real y el análisis de métricas de rendimiento en vivo.

Index Terms—Visión artificial, Drones, Redes Neuronales Convolucionales (CNN), Validación cruzada, Métricas de rendimiento, Inspección portuaria.

1. INTRODUCCIÓN Y CONTEXTO MECATRÓNICO

EL monitoreo automatizado del tráfico marítimo y la inspección de embarcaciones en zonas portuarias complejas representan un desafío crítico en la ingeniería mecatrónica moderna. Los sistemas de percepción embarcados en Vehículos Aéreos No Tripulados (UAVs / drones) operan bajo restricciones severas: capacidad de cómputo limitada a bordo, latencia estricta para la toma de decisiones en vuelo y la necesidad imperativa de mitigar los falsos positivos derivados de interferencias ambientales (como olas, estelas o infraestructura portuaria).

Este proyecto aborda el diseño de un clasificador binario de alta fiabilidad enfocado en la detección de barcos de carga a partir de imágenes aéreas satelitales normalizadas de 80×80 píxeles en formato RGB. Para cumplir con los requerimientos de la rúbrica institucional (apuntando a un Accuracy superior al 98 %), se estructuró un marco metodológico fundamentado en el aprendizaje automático supervisado, validación rigurosa y el análisis matemático del espacio de características visuales.

2. CRITERIO C1: METODOLOGÍA, ARQUITECTURA CNN Y TÉCNICAS DE OPTIMIZACIÓN (50 %)

2.1. Preprocesamiento y Normalización del Espacio de Entrada

El dataset original se compone de imágenes satelitales de 80×80 píxeles con tres canales de color (RGB). Como etapa fundamental de preprocesamiento, se aplicó una normalización min-max a escala flotante dividiendo la matriz de cada imagen por 255,0:

$$X_{norm} = \frac{X_{raw}}{255,0}, \quad X_{norm} \in [0,0,1,0]^{80 \times 80 \times 3} \quad (1)$$

Esta transformación estabiliza el comportamiento del optimizador estocástico *Adam* durante la retropropagación (*backpropagation*), evitando la saturación temprana de las funciones de activación y acelerando la tasa de convergencia en el espacio de pesos.

2.2. Arquitectura de la Red Neuronal Convolutional (CNN)

Para la extracción automática de descriptores visuales sin intervención humana, se diseñó una Red Neuronal Convolutional (CNN) secuencial profunda, estructurada jerárquicamente para aprender desde patrones espaciales de bajo nivel hasta representaciones semánticas complejas:

- **Bloque Convolutional 1:** Compuesto por una capa Conv2D de 32 filtros con un núcleo (*kernel*) de 3×3 y activación *ReLU* ($f(x) = \max(0, x)$), seguida de una capa MaxPooling2D de 2×2 . Esta capa inicial actúa como un filtro espacial encargado de detectar características elementales como bordes costeros, contrastes de color y orientaciones primarias.
- **Bloque Convolutional 2:** Utiliza 64 filtros de 3×3 con activación *ReLU* y *MaxPooling* de 2×2 . Su propósito es combinar los bordes primitivos para capturar formas geométricas intermedias y texturas

asociadas a las superestructuras portuarias y cascos de los buques.

- **Bloque Convolutivo 3:** Incrementa la abstracción con 128 filtros de 3×3 y *ReLU*, maximizando el campo receptivo global para identificar patrones estructurales complejos propios de los barcos de carga.
- **Capa de Aplanado y Clasificación (Fully Connected):** La matriz tridimensional resultante se aplanada mediante una capa *Flatten()* y se conecta a una capa densa (*Dense*) de 128 neuronas con activación *ReLU*.
- **Mecanismo de Regularización (Dropout):** Se implementó una tasa de *Dropout* (0.5) que desactiva aleatoriamente el 50 % de las conexiones sinápticas durante cada iteración de entrenamiento. Esto previene la coadaptación de las neuronas y mitiga drásticamente el sobreajuste (*overfitting*).
- **Capa de Salida:** Consta de una única neurona con función de activación *Sigmoid*:

$$\hat{y} = \sigma(z) = \frac{1}{1 + e^{-z}} \quad (2)$$

la cual mapea el valor de salida al intervalo (0, 1), interpretándose como la probabilidad estimada de que la imagen contenga una embarcación ($\hat{y} \geq 0,5 \rightarrow$ Barco).

2.3. Validación Cruzada Estratificada (5-Folds) y Estudio de Ablación

Para garantizar que el modelo no dependa de una partición de datos afortunada, se implementó un esquema de validación cruzada del tipo *Stratified Shuffle Split* con $n_splits = 5$ (Figura 1). Asimismo, se desarrolló un estudio comparativo de ablación frente a modelos base (Tabla 1).




Figura 1. Distribución porcentual del conjunto de datos bajo el esquema de partición estratificada.

Cuadro 1
Tabla Comparativa de Ablación y Optimización de Modelos

Modelo / Arquitectura	Estrategia	Acc	F1
1. Baseline MLP	Red Densa Plana	88,82 %	0,7361
2. CNN Básica	Sin Regularización	96,18 %	0,9222
3. CNN con Dropout	Propuesta Conv + Dropout	95,88 %	0,9213
4. Modelo Final (CV)	Optimizado GPU	98,71 %	0,9740

3. CRITERIO C2: EVALUACIÓN, VALIDACIÓN CRUZADA E INFERENCIA EN VIVO (50 %)

3.1. Análisis Dinámico de las Curvas de Aprendizaje

Las curvas de aprendizaje (Figura 2) documentan el comportamiento del modelo a lo largo de las épocas de entrenamiento con aceleración por GPU. Se observa que la precisión de entrenamiento (*Train Accuracy*) asciende de forma continua hasta estabilizarse por encima del 98 %, comportamiento emulado casi simétricamente por la precisión de validación (*Validation Accuracy*).

Simultáneamente, la función de costo (*Loss*) exhibe una disminución exponencial asintótica tanto en entrenamiento como en validación. La ausencia de divergencia pronunciada entre ambas curvas confirma que el modelo posee una excelente capacidad de generalización frente a datos no vistos.




Figura 2. Evolución del Accuracy y de la Pérdida (Loss) por época en el proceso de optimización.

3.2. Interpretación Analítica Profunda de las Métricas de Rendimiento

El desempeño del mejor modelo guardado (*mejor_modelo_barcos.h5*) se evaluó rigurosamente mediante métricas estadísticas globales calculadas a partir de la validación cruzada (Tabla 2):

Cuadro 2
Resultados Promedio de la Validación Cruzada (5-Folds)

Métrica de Evaluación	Valor Promedio
Accuracy Promedio	98,71 %
Precision Promedio	0,9781
Recall Promedio	0,9702
F1-Score Promedio	0,9740

- **Accuracy (98,71 %):** Indica la tasa de acierto global del sistema. En un entorno mecatrónico de monitoreo aéreo, significa que de cada 100 imágenes analizadas por el dron, aproximadamente 99 son clasificadas correctamente de manera absoluta, superando con holgura la meta exigida.
- **Precision (0,9781 o 97,81 %):** Mide la calidad de las predicciones positivas. Un valor de 0,9781 revela que cuando el algoritmo predice la presencia de un barco, tiene una fiabilidad cercana al 98 %. Esto minimiza de forma crítica los *falsos positivos* (evitar que el dron alerte erróneamente sobre la presencia de barcos inexistentes).
- **Recall (0,9702 o 97,02 %):** Sensibilidad o tasa de verdaderos positivos, mide la capacidad del modelo

para detectar todos los barcos reales presentes. Garantiza que al sistema se le escapan menos del 3 % de los objetivos reales, reduciendo drásticamente los *falsos negativos*.

- **F1-Score (0,9740):** Media armónica entre la precisión y el recall, confirmando un balance general óptimo del clasificador.

3.3. Análisis de la Matriz de Confusión y Curva ROC

La matriz de confusión (Figura 3) sobre el conjunto de prueba evaluado arroja un balance altamente favorable: 382 Verdaderos Negativos y 126 Verdaderos Positivos, con un margen de error sumamente reducido (0 falsos positivos y tan solo 2 falsos negativos).




Figura 3. Matriz de Confusión detallada del mejor modelo de clasificación binaria.

Por otro lado, la Curva ROC (Figura 4) traza la tasa de verdaderos positivos frente a la tasa de falsos positivos. El modelo alcanza un Área Bajo la Curva óptima de **AUC = 1.0000**, lo que corrobora matemáticamente una capacidad de discriminación perfecta entre ambas clases en el conjunto evaluado.




Figura 4. Curva ROC y el Área Bajo la Curva (AUC = 1.0000) del clasificador.

3.4. Validación en la Interfaz de Usuario (UI)

Para cumplir con los requerimientos operativos de la prueba en vivo, se desarrolló una aplicación web interactiva

en Streamlit. Esta plataforma procesa lotes de imágenes externas, ejecuta el reescalado estricto a 80×80 px, calcula la inferencia neuronal y permite el etiquetado manual interactivo mediante botones de respuesta rápida para contrastar el desempeño en tiempo real frente a las exigencias de la rúbrica institucional.




Figura 5. Interfaz iniciada sin imágenes cargadas para análisis

En la Figura 5 se aprecia el nombre del archivo cargado (*mejor_modelo_barcos.h5*) correspondiente al modelo optimizado. Adicionalmente, cuenta con el botón de carga masiva de imágenes de testeo y una barra deslizante para configurar el Umbral de Decisión (*Threshold*), permitiendo calibrar la sensibilidad de la IA ante casos límite.




Figura 6. Imágenes cargadas en la interfaz de usuario para etiquetado en vivo

En la Figura 6 se visualiza la galería con las imágenes de análisis y el resultado preliminar de la inferencia de la IA (IA: BARCO o IA: NO BARCO) junto con su respectivo porcentaje de confianza.




Figura 7. Etiquetado de las imágenes en vivo mediante botones interactivos

La Figura 7 muestra el proceso de validación interactiva mediante botones de respuesta rápida, los cuales permiten registrar de forma inmediata el valor real (*Ground Truth*) y verificar si la predicción de la IA fue un acierto o un fallo.




Figura 8. Métricas obtenidas y matriz de confusión en tiempo real

Finalmente, la Figura 8 presenta el consolidado oficial de métricas en tiempo real, evaluando dinámicamente el Accuracy frente a la meta institucional del 98 %.

4. CONCLUSIONES

El proyecto cumplió de manera sobresaliente con las especificaciones técnicas y los lineamientos de la rúbrica para el segundo corte. La implementación de la Red Neuronal Convolutiva, respaldada por un preprocesamiento adecuado y validación cruzada, demostró ser una solución idónea para la tarea de visión artificial embarcada, superando el umbral de desempeño estipulado (98,71 % de accuracy global) y consolidando un sistema robusto, escalable y listo para su integración en plataformas mecatrónicas autónomas.

REFERENCIAS

- [1] Maritime Executive, *Rotterdam tests drones for ship inspections and monitoring the port*. Disponible en línea: <https://maritime-executive.com>
- [2] IOP Conference Series, *Artículo técnico de referencia sobre inspección portuaria y visión artificial en UAVs*, vol. 557, 2020.
- [3] Rhammell, *Ships in Satellite Imagery Dataset*, Kaggle. Disponible en línea: <https://www.kaggle.com>