

Sistema de Percepción Autónoma para Detección de Barcos de Carga en Entornos Portuarios mediante Visión Artificial y Redes Neuronales Convolucionales

David Alejandro Poveda Jimenez

Código Estudiantil: 7004156

Ingeniería Mecatrónica UMNG – Inteligencia Artificial



Resumen—Este documento presenta el diseño, desarrollo y validación integral de un sistema de clasificación binaria (barco / no barco) basado en Redes Neuronales Convolucionales (CNN), concebido para integrarse en la carga útil de percepción y visión artificial de un Vehículo Aéreo No Tripulado (UAV). Utilizando un conjunto de datos de imágenes aéreas satelitales (80×80 píxeles, RGB), se implementó un pipeline riguroso que abarca la normalización espacial, la extracción automática de descriptores visuales jerárquicos y una validación cruzada estratificada de 5 pliegues (5-folds). El modelo optimizado alcanzó un Accuracy global promedio del 98,17 % y un F1-Score de 0,9635, superando el umbral de exigencia institucional. Asimismo, se desarrolló una Interfaz de Usuario (UI) interactiva para la validación en tiempo real y el análisis de métricas de rendimiento en vivo.

Index Terms—Visión artificial, Drones, Redes Neuronales Convolucionales (CNN), Validación cruzada, Métricas de rendimiento, Inspección portuaria.

1. INTRODUCCIÓN Y CONTEXTO MECATRÓNICO

El monitoreo automatizado del tráfico marítimo y la inspección de embarcaciones en zonas portuarias complejas representan un desafío crítico en la ingeniería mecatrónica moderna. Los sistemas de percepción embarcados en Vehículos Aéreos No Tripulados (UAVs / drones) operan bajo restricciones severas: capacidad de cómputo limitada a bordo, latencia estricta para la toma de decisiones en vuelo y la necesidad imperativa de mitigar los falsos positivos derivados de interferencias ambientales (como olas, estelas o infraestructura portuaria).

Este proyecto aborda el diseño de un clasificador binario de alta fiabilidad enfocado en la detección de barcos de carga a partir de imágenes aéreas satelitales normalizadas de 80×80 píxeles en formato RGB. Para cumplir con los requerimientos de la rúbrica institucional (apuntando a un Accuracy superior al 98 %), se estructuró un marco metodológico fundamentado en el aprendizaje automático supervisado, validación rigurosa y el análisis matemático del espacio de características visuales.

2. CRITERIO C1: METODOLOGÍA, ARQUITECTURA CNN Y TÉCNICAS DE OPTIMIZACIÓN (50 %)

2.1. Preprocesamiento y Normalización del Espacio de Entrada

El dataset original se compone de imágenes satelitales de 80×80 píxeles con tres canales de color (RGB). Como etapa fundamental de preprocesamiento, se aplicó una normalización min-max a escala flotante dividiendo la matriz de cada imagen por 255,0:

$$X_{norm} = \frac{X_{raw}}{255,0}, \quad X_{norm} \in [0,0, 1,0]^{80 \times 80 \times 3} \quad (1)$$

Esta transformación estabiliza el comportamiento del optimizador estocástico *Adam* durante la retropropagación (*backpropagation*), evitando la saturación temprana de las funciones de activación y acelerando la tasa de convergencia en el espacio de pesos.

2.2. Arquitectura de la Red Neuronal Convolutional (CNN)

Para la extracción automática de descriptores visuales sin intervención humana, se diseñó una Red Neuronal Convolutional (CNN) secuencial profunda, estructurada jerárquicamente para aprender desde patrones espaciales de bajo nivel hasta representaciones semánticas complejas:

- **Bloque Convolutional 1:** Compuesto por una capa *Conv2D* de 32 filtros con un núcleo (*kernel*) de 3×3 y activación *ReLU* ($f(x) = \max(0, x)$), seguida de una capa *MaxPooling2D* de 2×2 . Esta capa inicial actúa como un filtro espacial encargado de detectar características elementales como bordes costeros, contrastes de color y orientaciones primarias.
- **Bloque Convolutional 2:** Utiliza 64 filtros de 3×3 con activación *ReLU* y *MaxPooling* de 2×2 . Su propósito es combinar los bordes primitivos para capturar formas geométricas intermedias y texturas

asociadas a las superestructuras portuarias y cascos de los buques.

- **Bloque Convolutivo 3:** Incrementa la abstracción con 128 filtros de 3×3 y *ReLU*, maximizando el campo receptivo global para identificar patrones estructurales complejos propios de los barcos de carga.
- **Capa de Aplanado y Clasificación (Fully Connected):** La matriz tridimensional resultante se aplanar mediante una capa *Flatten()* y se conecta a una capa densa (*Dense*) de 128 neuronas con activación *ReLU*.
- **Mecanismo de Regularización (Dropout):** Se implementó una tasa de *Dropout* (0.5) que desactiva aleatoriamente el 50 % de las conexiones sinápticas durante cada iteración de entrenamiento. Esto previene la coadaptación de las neuronas y mitiga drásticamente el sobreajuste (*overfitting*).
- **Capa de Salida:** Consta de una única neurona con función de activación *Sigmoid*:

$$\hat{y} = \sigma(z) = \frac{1}{1 + e^{-z}} \quad (2)$$

la cual mapea el valor de salida al intervalo (0,1), interpretándose como la probabilidad estimada de que la imagen contenga una embarcación ($\hat{y} \geq 0,5 \rightarrow$ Barco).

2.3. Validación Cruzada Estratificada (5-Folds)

Para garantizar que el modelo no dependa de una partición de datos afortunada, se implementó un esquema de validación cruzada del tipo *Stratified Shuffle Split* con $n_splits = 5$, manteniendo una proporción estricta de 85 % para entrenamiento y 15 % para validación en cada pliegue, preservando la distribución de clases original (Figura 1).




Figura 1. Distribución porcentual del conjunto de datos bajo el esquema de partición estratificada.

3. CRITERIO C2: EVALUACIÓN, VALIDACIÓN CRUZADA E INFERENCIA EN VIVO (50 %)

3.1. Análisis Dinámico de las Curvas de Aprendizaje

Las curvas de aprendizaje (Figura 2) documentan el comportamiento del modelo a lo largo de las épocas de entrenamiento. Se observa que la precisión de entrenamiento (*Train Accuracy*) asciende de forma continua hasta estabilizarse cerca del 98 %, comportamiento emulado casi

simétricamente por la precisión de validación (*Validation Accuracy*).

Simultáneamente, la función de costo (*Loss*) exhibe una disminución exponencial asintótica tanto en entrenamiento como en validación. La ausencia de divergencia pronunciada entre ambas curvas confirma que el modelo posee una excelente capacidad de generalización frente a datos no vistos.




Figura 2. Evolución del Accuracy y de la Pérdida (Loss) por época en el proceso de optimización.

3.2. Interpretación Analítica Profunda de las Métricas de Rendimiento

El desempeño del mejor modelo guardado (*mejor_modelo_barcos.h5*) se evaluó rigurosamente mediante métricas estadísticas globales calculadas a partir de la validación cruzada (Tabla 1):

Cuadro 1
Resultados Promedio de la Validación Cruzada (5-Folds)

Métrica de Evaluación	Valor Promedio
Accuracy Promedio	98,17 %
Precision Promedio	0,9628
Recall Promedio	0,9653
F1-Score Promedio	0,9635

- **Accuracy (98,17 %):** Indica la tasa de acierto global del sistema. En un entorno mecatrónico de monitoreo aéreo, significa que de cada 100 imágenes analizadas por el dron, aproximadamente 98 son clasificadas correctamente de manera absoluta.
- **Precision (0,9628 o 96,28 %):** Mide la calidad de las predicciones positivas. Un valor de 0,9628 revela que cuando el algoritmo predice la presencia de un barco, tiene una fiabilidad superior al 96 %. Esto minimiza de forma crítica los **falsos positivos** (es decir, evitar que el dron alerte falsamente sobre la presencia de barcos inexistentes debido a olas u objetos extraños).
- **Recall (0,9653 o 96,53 %):** Denominado también sensibilidad o tasa de verdaderos positivos, mide la capacidad del modelo para detectar todos los barcos reales presentes en el entorno. Un recall de 96,53 % garantiza que al sistema se le escapan menos del 3,5 % de los objetivos reales, reduciendo drásticamente los **falsos negativos** (evitar que el dron ignore barcos de carga reales).
- **F1-Score (0,9635):** Al representar la media armónica entre la precisión y el recall, esta métrica confirma

la robustez del balance general del clasificador, demostrando que el modelo no sacrifica una métrica en favor de la otra.

3.3. Análisis de la Matriz de Confusión y Curva ROC

La matriz de confusión (Figura 3) sobre el conjunto de prueba evaluado arroja un balance altamente favorable: 450 Verdaderos Negativos (No Barcos correctamente clasificados) y 149 Verdaderos Positivos (Barcos detectados con éxito), con un saldo casi nulo de errores (0 falsos positivos y solo 1 falso negativo).




Figura 3. Matriz de Confusión detallada del mejor modelo de clasificación binaria.

Por otro lado, la Curva ROC (Figura 4) traza la tasa de verdaderos positivos frente a la tasa de falsos positivos en diversos umbrales de decisión. El modelo alcanza un Área Bajo la Curva de $AUC = 0.9999$, lo que corrobora matemáticamente una capacidad de discriminación casi perfecta entre ambas clases.




Figura 4. Curva ROC y el Área Bajo la Curva ($AUC = 0.9999$) del clasificador.

3.4. Validación en la Interfaz de Usuario (UI)

Para cumplir con los requerimientos operativos de la prueba en vivo, se desarrolló una aplicación web interactiva en Streamlit. Esta plataforma procesa lotes de imágenes externas, ejecuta el reescalado estricto a 80×80 px, calcula

la inferencia neuronal y permite el etiquetado manual interactivo para contrastar el desempeño en tiempo real frente a las exigencias de la rúbrica institucional.




Figura 5. Interfaz iniciada sin imágenes cargadas para análisis

En la imagen se aprecia el nombre del archivo (`mejor_modelo_barcos.h5`) el cual fue el modelo mejor entrenado con mayor accuracy, por esta razón se carga a la interfaz gráfica, adicional a esto se encuentra el botón para cargar las respectivas imágenes de testeo y una barra para el Umbral de Decisión (Threshold), con este se puede modificar que tan exigente será la IA, en un valor muy alto indicaría que si la IA no está 100% seguro de que la imagen es un barco por más que si lo sea lo pondrá como NO BARCO y viceversa.




Figura 6. Imágenes cargadas en la interfaz de usuario para etiquetado en vivo

En la figura 6 se observa que ya se subieron las respectivas imágenes de análisis, además del respectivo etiquetado de la IA, donde esta dice IA:BARCO o IA:NO BARCO y el porcentaje de confianza en su decisión, una vez se suele se puede abrir una lista desplegable con el fin de realizar el etiquetado correcto y verificar si la IA hizo la predicción correcta o incorrecta.




Figura 7. Etiquetado de las imágenes en vivo

Como se observa en la figura 7 ya se realizó el etiquetado en vivo de las imágenes subidas, además de decir si hubo acierto o fallo, en este caso la IA acertó en todos los casos, por lo que a continuación se verá el consolidado de métricas en vivo.



Figura 8. Métricas obtenidas y matriz de confusión

4. CONCLUSIONES

El proyecto cumplió de manera sobresaliente con las especificaciones técnicas y los lineamientos de la rúbrica para el segundo corte. La implementación de la Red Neuronal Convolutiva, respaldada por un preprocesamiento adecuado y validación cruzada, demostró ser una solución idónea para la tarea de visión artificial embarcada, superando el umbral de desempeño estipulado ($> 98\%$ de accuracy) y consolidando un sistema robusto, escalable y listo para su integración en plataformas mecatrónicas autónomas.

REFERENCIAS

- [1] Maritime Executive, *Rotterdam tests drones for ship inspections and monitoring the port*. Disponible en línea: <https://maritime-executive.com>
- [2] IOP Conference Series, *Artículo técnico de referencia sobre inspección portuaria y visión artificial en UAVs*, vol. 557, 2020.
- [3] Rhammell, *Ships in Satellite Imagery Dataset*, Kaggle. Disponible en línea: <https://www.kaggle.com>